

现有小分子药物设计相关数据集调研及新整合数据库的Benchmark设计思考报告

1. 引言

在现代药物设计与发现领域，小分子数据库扮演着至关重要的角色。这些数据库汇集了大量的化学信息和生物活性数据，极大地推动了虚拟筛选、定量构效关系(QSAR)模型构建等计算方法的应用，从而加速了新药的研发进程。随着数据量的持续增长和复杂性的日益增加，对高质量、整合性资源的需求也变得愈发迫切，以期更高效、更精准地进行药物开发。本报告旨在对现有广泛使用的小分子数据库进行深入调研，分析其数据量、包含信息、特色优势、应用领域、数据质量控制以及现有缺陷，并在此基础上，思考如何为新的整合数据库设计Benchmark，以证明其在覆盖率、数据质量、信息整合能力、用户友好性和最新性等方面优于现有资源。

2. 主要小分子数据库概述

本报告将重点分析以下八个在小分子药物设计领域广泛使用的数据库：ChEMBL、ZINC、PubChem、DrugBank、BindingDB、PDBbind、DUDE 和 LIT-PCBA。每个数据库都拥有其独特的数据特点和应用领域，共同构成了小分子药物设计的重要信息基础。

3. 现有数据库的深入分析

3.1. ChEMBL

- 当前状态与数据量：ChEMBL 数据库是一个人工管理、高质量、大规模、开放的生物活性分子数据库，这些分子具有类药特性¹。最新发布的 ChEMBL 34 版本(2024 年 3 月)包含 2,431,025 个化合物(其中 2,409,270 个带有 mol 文件)，3,106,257 个化合物记录，20,772,701 个活性数据，1,644,390 个生物测定，15,598 个靶点和 89,892 篇文献³。ChEMBL 35 版本已于 2024 年 12 月发布⁴，虽然具体统计数据在提供的材料中是针对 34 版本的，但其持续增长的趋势表明了该数据库不断扩充的规模。ChEMBL 数据量和多样性的持续增长¹表明其致力于整合最新的药物化学研究成果。此外，收录的直接提交数据量相对于文献提取数据量的增加¹可能预示着对一级研究的更强关注以及来自直接提交的更标准化数据格式。ChEMBL 拥有超过 2000 万个活性数据点³，这突显了其在生物活性研究中的重要价值。
- 包含信息与属性：ChEMBL 包含 SMILES、InChI、分子量、LogP 等基本分子属性，以及各种生物活性数据，如 IC50、Ki 和 Kd 值¹。它还提供靶点信息，包括 UniProt IDs⁵，以及一些疾病适应症信息³。该数据库整合了针对抗 SARS-CoV-2 活性筛选的化合物的精选数据以及新的专利生物活性数据¹。此外，ChEMBL 还提供天然产物相似性评分、天然产物和化学探针的标记，以及生物活性的作用类型注释¹。人工管理的分子序列数据(INN 和 USAN 的蛋白质和核酸序列)以及扩展的药物适应症覆盖范围，并映射到 MeSH 和 EFO 本体³。ChEMBL 信息的广泛性，从基本的分子性质到详细的生物活

性和靶点数据, 以及天然产物相似性等专门注释, 使其成为各种药物设计任务的多功能资源。专利数据的纳入¹ 对于识别可能未在传统文献中发表的新化学实体和生物活性尤其有价值。

- 主要特色与优势: ChEMBL 的主要特色在于其人工管理, 保证了数据的质量¹。它是一个大规模且开放获取的数据库¹, 为研究社区广泛可用, 促进了合作并加速了研究进展。ChEMBL 遵循 FAIR 原则 (Findable, Accessible, Interoperable, Reusable, 可查找、可访问、可互操作、可重用)¹, 并被认为是全球核心生物数据资源。它涵盖多种生物活性数据类型和时间段¹, 并包含来自直接提交数据集和文献提取的数据¹, 提供了已发表和直接提交数据的全面视图。ChEMBL 对人工管理和遵循 FAIR 原则的重视使其成为科学界可靠且有价值的资源。其开放获取的性质促进了合作和数据共享, 可能加速药物发现领域的突破。ChEMBL 在 EMBL-EBI 最常用的资源中排名第五¹, 这进一步强调了其在科学界的重要性。
- 药物设计应用: ChEMBL 被广泛应用于学术界、生物技术公司和大型制药企业等各个领域¹。它适用于虚拟筛选 (从大型化合物库中识别潜在的候选药物)、QSAR 模型构建 (基于化学结构预测生物活性)、靶点识别 (寻找已知生物活性分子的潜在靶点) 和生物活性预测 (预测新分子对已知靶点的活性)。
- 数据质量控制: ChEMBL 由专家人工管理¹, 这包括对从文献中提取和用户提交的数据进行仔细审查和验证。它采用标准化方法和数据清理流程 (尽管具体细节在提供的材料中未详细说明), 标准化确保了数据表示的一致性, 而清理则消除了错误和不一致性。ChEMBL 还采用去重策略来维护独特的化合物集合³, 防止冗余并确保分析基于不同的化学实体。
- 现有缺陷和改进方向: 虽然人工管理提高了数据质量, 但也可能耗时, 导致最新数据纳入的延迟。文献发表和数据库收录之间的时间差可能会影响研究的时效性。由于信息来自不同的来源和文献, 数据不一致性仍然可能存在, 不同的研究团队可能使用不同的实验协议和报告标准。

3.2. ZINC

- 当前状态与数据量: ZINC 是一个免费的、用于虚拟筛选的商业可用化合物数据库⁶, 其主要关注点是可用于实验验证的分子。该数据库持续更新, 最新的网站界面版本是 "ZINC-22"⁷, 表明其不断改进用户界面和潜在的基础数据。截至 2023 年, 据称包含超过 370 亿个商业可用分子⁷, 如此庞大的规模使其成为大规模虚拟筛选的首选资源。其中超过 45 亿个化合物已构建为生物学相关的、可直接用于对接的 3D 格式⁸, 这些预先计算的 3D 结构显著节省了研究人员的计算时间。ZINC 庞大的规模, 特别是按需合成库¹⁰, 为虚拟筛选提供了无与伦比的资源。预先计算的 3D 格式的可用性显著加速了对接研究, 使得高效筛选数十亿个化合物成为可能。其持续增长¹⁰ 预示着发现新先导化合物的潜力不断扩大。
- 包含信息与属性: ZINC 包含 SMILES 和可直接用于对接的 3D 格式⁶, 这些对于对接模拟和基于配体的建模至关重要。它还提供物理性质, 如构象、部分原子电荷、cLogP 值和溶剂化能⁸, 这些性质对于估计结合亲和力和 ADMET (吸收、分布、代谢、排泄和

毒性)性质至关重要。ZINC 还包含商业可用化合物及其可搜索的类似物的信息⁶, 这有助于获取已识别的命中化合物并探索其周围的化学空间。ZINC 对商业可用化合物的关注使其对于希望实验验证虚拟筛选结果的研究人员来说非常实用。包含计算的物理性质通过为化合物的过滤和优先级排序提供有价值的数据, 进一步增强了其在计算药物设计中的实用性。搜索类似物的能力扩展了先导化合物优化的潜力。

- 主要特色与优势: ZINC 的主要特色在于其极其庞大的规模, 拥有数十亿个化合物⁷, 这增加了发现新命中的机会。它专注于商业可用的分子⁶, 简化了获取和测试已识别化合物的过程。ZINC 以可直接用于对接的 3D 格式提供⁶, 节省了大量的计算资源和时间。该数据库对所有人免费开放⁷, 降低了药物发现研究的门槛。ZINC 持续更新⁷, 确保数据库与商业可用化学空间的最新添加保持同步。ZINC 的主要优势在于其庞大的规模和对易于获得的化合物的关注, 使其成为初始虚拟筛选工作的首选资源。其免费访问进一步普及了药物发现研究, 允许资源有限的研究人员参与大规模筛选。持续的更新确保了其在快速发展的化学品市场中的相关性。其使用统计数据¹⁰ 表明了其在社区内的受欢迎程度。
- 药物设计应用: ZINC 主要用于虚拟筛选⁶, 其庞大的规模使其适用于针对各种靶点的筛选。ZINC 还提供类似物搜索功能⁶, 允许研究人员查找与已知活性化合物结构相似的化合物。
- 数据质量控制: ZINC 采用数据组织方法来实现快速查找和检索⁸, 高效的搜索算法对于处理如此庞大的数据库至关重要。其管理和托管基础设施位于大型计算集群上⁸, 确保数据库的稳健性并能处理高流量。ZINC 根据重原子计数和 logP 值对分子进行分箱⁸, 这有助于基于相关性性质高效地搜索和分子数据库的子集。
- 现有缺陷和改进方向: 如此庞大的规模使得在没有适当工具和策略的情况下进行搜索和过滤可能具有挑战性。导航数十亿个化合物需要复杂的搜索功能和过滤条件。虽然 ZINC 专注于商业可用性, 但实际的可用性和合成成功率可能因供应商而异¹⁰。虽然 "按需合成" 库非常庞大, 但它们需要合成, 而合成的成功率可能会有所不同。

3.3. PubChem

- 当前状态与数据量: PubChem 是一个包含小分子及其生物活性的综合数据库¹¹, 它作为来自众多来源的化学信息的中央存储库。截至 2025 年 1 月, PubChem 包含超过 1000 个数据来源, 1.19 亿个化合物, 3.22 亿个物质和 2.95 亿个生物活性数据¹¹, 不断添加新的数据来源和记录突显了其动态特性。截至 2024 年 9 月, 统计数据相似: 3.22 亿个物质, 1.19 亿个化合物和来自 167 万个生物测定的 2.95 亿个生物活性数据¹¹, 这些跨不同报告的一致数字表明了数据库的稳定性和规模。PubChem 庞大的化合物、物质和生物活性数据集, 来源于广泛的贡献者¹¹, 使其成为探索化学生物学关系的重要资源。整合来自文献和专利的数据¹¹ 进一步增强了其范围, 提供了化学实体的多方面视图。每月超过 400 万的用户访问量¹⁴ 强调了其在科学界的重要性。
- 包含信息与属性: PubChem 包含物质(化学描述)、化合物(独特结构)、生物测定(生物实验)、生物活性(活性数据点)、蛋白质、基因、通路、细胞系、分类学、文献和专利¹¹。这种广泛的数据类型允许进行全面的分析。它提供来自 Thieme Chemistry 的化

学文献链接, 来自 SpringerMaterials 的化学和物理性质链接, 以及来自 WIPO 的专利链接¹⁴, 这些链接有助于探索相关信息和更深入的理解。PubChem 还包含一个与 COVID-19 和 SARS-CoV-2 相关的特殊数据集¹⁴, 这表明了 PubChem 对新兴健康危机的响应能力。PubChem 还整合了与药物 (FDA NDC 目录, 绿皮书, DILrank, HIV/AIDS 药物)、化学健康和安全 (Haz-Map, IARC, EPA AEGLs) 以及 CAS 登记号相关的注释¹², 这增强了其在药物安全和监管信息方面的价值。PubChem 的优势在于其综合性, 整合了超越化学结构和生物活性的各种信息。纳入安全数据、文献链接和专利信息提供了化学实体的全面视图, 支持从基础科学到药物开发和安全评估的广泛研究问题。PubChemRDF 的扩展, 包括文献共现数据¹¹, 进一步实现了基于语义网的复杂探索。

- 主要特色与优势: PubChem 具有大规模和综合性, 涵盖广泛的化学和生物数据¹¹。它汇集了来自众多来源 (超过 1000 个) 的数据¹¹, 减少了研究人员查阅多个独立数据库的需求。PubChem 是免费且公开可用的¹⁵, 促进了全球研究人员的广泛使用和可访问性。它提供跨不同数据库和资源的相关信息链接¹⁴, 有助于数据整合和知识发现。PubChem 还提供专门的数据集, 例如 COVID-19 相关数据集¹⁴, 这表明了其适应当前科学优先事项的能力。PubChem 作为一个化学信息的中心枢纽, 促进了来自不同来源的数据整合。其免费可访问性使其成为全球研究人员的重要资源, 特别是那些资源有限的研究人员。新界面的开发, 如综合文献面板和专利知识面板¹¹, 表明其不断努力改进用户体验和数据可访问性。
- 药物设计应用: PubChem 可用于靶点识别、虚拟筛选、生物活性分析以及探索化学-蛋白质-疾病关系。大量的生物活性数据使其适用于训练机器学习模型。文献和专利链接有助于发现新化合物及其潜在应用。研究人员可以追踪化学实体的历史和发展。
- 数据质量控制: 数据由贡献者提供, 其管理水平各不相同¹¹, 这可能会导致数据质量的异质性。NCBI 执行一定程度的标准化和整合, 努力协调来自不同来源的数据。指向原始数据源的链接允许用户验证信息, 这提高了透明度并允许用户评估数据的可靠性。
- 现有缺陷和改进方向: 数据质量可能因来源和贡献者的管理水平而异, 数据量庞大使得难以确保所有记录的质量一致。物质记录中存在冗余¹¹, 多个贡献者可能会提交关于同一化学实体的信息, 导致条目冗余。导航大量数据可能具有挑战性, 庞大的规模和复杂性需要有效的搜索和过滤工具。

3.4. DrugBank

- 当前状态与数据量: DrugBank 是一个生物信息学和化学信息学资源, 它将药物数据与药物靶点信息相结合¹⁶, 其重点专门针对药物及其与生物系统的相互作用。最新版本 (5.1.13 版, 2025 年 1 月) 包含 17,461 个药物条目, 其中包括 2,990 种已批准的小分子药物, 1,718 种已批准的生物制剂, 135 种营养保健品和超过 6,918 种实验性药物¹⁷, 详细的分类提供了对所包含药物类型的深入了解。它还链接到 5,468 个非冗余蛋白质序列¹⁷, 这种与靶点序列的直接联系是其关键特征。DrugBank 6.0 版于 2024 年发布, 显示已批准药物 (增长 72%)、研究性药物 (增长 38%) 和药物-药物相互作用 (增长 300%) 显著增长¹⁸, 这突显了数据库的持续扩展和信息深度。DrugBank 专注于药物

数据以及详细的靶点信息,使其成为理解药物作用机制和潜在相互作用的专门资源。同时包含小分子药物和生物制剂扩大了其适用性,顺应了生物治疗日益增长的重要性。最新版本中药物-药物相互作用数据的显著增加¹⁸使其对于安全性和多药理学研究尤其有价值。

- 包含信息与属性: 每个 DrugBank 药物条目包含超过 200 个数据字段,涵盖药物/化学数据和药物靶点/蛋白质数据¹⁷,如此广泛的属性集为每种药物提供了丰富的信息。它包括药物适应症、药物-药物相互作用、药物-食物相互作用、药物代谢、药代动力学等信息¹⁸,这种全面的药理学数据对于理解药物在体内的行为至关重要。DrugBank 还为许多小分子药物提供了实验和预测的 MS/MS 谱、1D/2D-NMR 谱、CCS、RT 和 RI 数据¹⁸,这些光谱数据对于药物识别和表征非常有价值。最新版本中增加了数千条新的、色彩丰富、注释详尽的通路,描绘了药物作用机制和药物代谢¹⁸,这些可视化表示有助于理解复杂的生物过程。DrugBank 条目中信息的深度,包括详细的药理学和化学性质以及可视化通路,为药物研发提供了丰富的背景信息。研究人员可以访问每种药物的广泛数据,从而深入分析其性质和相互作用。添加光谱数据进一步增强了其在分析化学和药物识别方面的实用性。
- 主要特色与优势: DrugBank 将详细的药物数据与全面的药物靶点信息相结合¹⁶,这种整合对于理解药物在分子水平上如何发挥作用至关重要。它同时包含小分子药物和生物制剂¹⁷,这种广泛的覆盖范围反映了现代治疗学的多样性。DrugBank 提供关于药物相互作用、代谢和药代动力学的广泛信息¹⁸,这对于评估药物安全性并预测其在体内的行为至关重要。它还包含药物机制的注释丰富的通路¹⁸,这些可视化辅助工具增强了对复杂药理过程的理解。DrugBank 在生物医学研究和临床应用中广泛使用¹⁸,其受欢迎程度表明了它对科学和医学界的价值。DrugBank 集成性质,专注于药物及其靶点之间的相互作用,使其区别于主要关注化学结构或生物活性的数据库。这使得它对于理解药物作用、预测副作用和识别潜在的药物再利用机会尤其有价值。详细的通路和相互作用数据对于研究药物机制的研究人员尤其有用。
- 药物设计应用: DrugBank 可用于靶点识别和验证。研究人员可以使用 DrugBank 查找针对特定蛋白质的已知药物。它还可用于预测药物-药物相互作用,其广泛的相互作用数据有助于识别潜在的安全问题。DrugBank 还有助于理解药物的作用机制和代谢,其通路信息提供了关于药物如何工作以及如何体内代谢的见解。此外,它还支持药代动力学和药效学研究,提供关于药物吸收、分布、代谢和排泄的数据。
- 数据质量控制: DrugBank 的数据由专家管理和维护,确保了高度的准确性和可靠性。定期更新确保数据库反映最新的研究和批准信息,保持信息的时效性和相关性。
- 现有缺陷和改进方向: 虽然 DrugBank 非常全面,但它并非完全开放获取;某些功能和数据需要订阅,这可能会限制一些研究人员的访问。

3.5. BindingDB

- 当前状态与数据量: BindingDB 是一个公开的数据库,其中包含小分子和蛋白质之间实验测量的结合亲和力数据⁵,其主要关注点是提供分子相互作用的定量数据。截至 2025 年 3 月, BindingDB 包含 300 万个数据点,涉及 130 万个化合物和 9500 个靶

点¹⁹，如此庞大的数据量支持计算模型的训练和验证。2024 年的更新报告了 290 万个结合测量数据，涵盖 130 万个化合物和数千个蛋白质靶点⁵，这些数字的一致性表明这是一个稳定且不断增长的资源。BindingDB 专注于定量结合亲和力数据，特别是 K_i 、 K_d 、 IC_{50} 和 EC_{50} 值，使其对于训练和验证预测药物-靶点相互作用的计算模型至关重要。专利数据的管理⁵ 为其内容增加了独特的维度，提供了可能在其他地方无法获得的结合数据。数据集的快速增长⁵ 表明其对研究社区的价值日益增加。

- 包含信息与属性：BindingDB 主要包含实验测量的结合亲和力 (K_i 、 K_d 、 IC_{50} 、 EC_{50})，单位为 nM⁵，这种标准化的单位有助于比较不同实验的结果。它涵盖 130 万个化合物和数千个蛋白质靶点⁵，如此广泛的覆盖范围允许研究各种分子相互作用。数据组织成与科学文章或专利相关的条目⁵，这为每个数据点提供了背景和可追溯性。注释包括指向 PDB 共晶体结构、UniProt IDs 以及化学数据库/目录链接的链接⁵，这些链接通过将数据连接到结构信息和其他相关资源来增强数据的价值。BindingDB 管理自 2013 年以来的美国专利¹⁹，这种对专利数据的关注提供了一个独特的结合信息来源。BindingDB 中详细的注释，将亲和力数据与结构信息和其他相关数据库联系起来，增强了其在基于结构的药物设计和理解结合相互作用背景方面的价值。研究人员可以轻松访问相关的结构数据和蛋白质信息，从而更深入地理解结合的分子基础。正在进行的数据管理工作¹⁹ 确保数据库保持最新和准确。
- 主要特色与优势：BindingDB 专注于实验测量的结合亲和力⁵，这为定量分析提供了高质量的数据。它是一个公开可访问的 FAIRsharing 资源¹⁹，促进了开放科学和数据共享。BindingDB 还包括从美国专利中管理的数据⁵，这为药物发现提供了独特的视角。它提供指向 PDB 中结构数据的链接⁵，有助于基于结构的结合相互作用分析。BindingDB 是一个快速增长的数据集⁵，确保了数据库的持续相关性和日益增长的实用性。BindingDB 通过提供大量公开可访问的定量结合数据，填补了一个关键的空白，这对于推进计算药物发现方法至关重要。专利数据的纳入提供了获取可能未在传统学术文献中报告的新型药物-靶点相互作用的机会。其作为 FAIR 资源的地位进一步增强了其可用性和与其他数据库的互操作性。
- 药物设计应用：BindingDB 可用于训练和验证结合亲和力预测的评分函数和机器学习模型²¹，其定量数据非常适合此目的。研究人员可以使用它来识别特定蛋白质靶点的配体，通过搜索已知对其靶点具有亲和力的化合物。BindingDB 还有助于理解构效关系，亲和力数据和结构链接的结合促进了 SAR 研究。
- 数据质量控制：BindingDB 的数据由 BindingDB 管理员从科学文献和专利中管理¹⁹，这种人工管理确保了高水平的数据质量。管理过程添加注释并链接到其他数据库⁵，这增强了数据的价值和背景信息。
- 现有缺陷和改进方向：BindingDB 主要关注蛋白质-小分子相互作用，而其他类型的结合(如蛋白质-蛋白质)的数据量较小，这可能会限制其在对其他相互作用类型感兴趣的研究人员中的使用。

3.6. PDBbind

- 当前状态与数据量：PDBbind 提供来自 PDB 的生物分子复合物的实验结合亲和力数

据²²，它直接将结构信息与结合能量学联系起来。最新版本是 2024 版，基于 2024 年初 PDB 的内容²²，此年度更新确保数据库与最新的结构信息保持同步。它提供总共 33,653 个生物分子复合物的结合亲和力数据，包括蛋白质-配体(27,385 个)、蛋白质-蛋白质(4,594 个)、蛋白质-核酸(1,440 个)和核酸-配体复合物(234 个)²²，包含各种复合物类型拓宽了其用途。与最后一个免费访问版本(2020 版)相比，结合数据增加了 43%²²，这种显著的增长突显了扩大数据库的持续努力。它提供一个“标准精炼集”(5,777 个复合物)和一个“扩展精炼集”(7,084 个复合物，包括含金属蛋白质)，这些都是高质量的蛋白质-配体复合物²²，这些精炼集对于基准测试对接和评分方法尤其有价值。PDBbind 直接将来自 PDB 的结构信息与定量结合亲和力数据联系起来，使其成为基于结构的药物设计和对接/评分方法开发的重要资源。可用于计算研究的高质量精炼数据集的可用性进一步增强了其在基准测试和验证新算法方面的实用性。最新版本中数据量的显著增加²²强调了其在该领域持续的重要性。

- 包含信息与属性：PDBbind 包含各种类型的生物分子复合物的实验结合亲和力数据(K_d、K_i、IC₅₀)²²，这些定量数据对于计算研究至关重要。它直接链接到蛋白质数据库(PDB)中的 3D 结构²²，这使得研究人员可以直接分析结合的结构基础。PDBbind 还包括一个高质量的蛋白质-配体复合物精炼集，适用于对接/评分研究²²，这个精选的子集被广泛用于方法验证。数据来源于超过 53,400 篇同行评审的出版物²²，这确保了数据的可靠性和准确性。PDBbind 将结合数据与 PDB 中的 3D 结构直接联系起来，这是一个独特而强大的功能，使研究人员能够直接研究分子识别的结构基础并开发基于结构的药物设计策略。精炼集为社区提供了一个宝贵的资源，用于使用一致且高质量的数据集比较和验证计算方法。从大量出版物中管理数据²²表明了数据库的全面性。
- 主要特色与优势：PDBbind 直接将结合亲和力数据与 PDB 中的 3D 结构联系起来²²，这是一个在所有数据库中并不常见的功能。它提供高质量的数据集用于基准测试²²，这些数据集已成为方法验证的社区标准。PDBbind 包含各种生物分子复合物类型的大量结合数据²²，这使其适用范围超越了蛋白质-配体相互作用。它定期年度更新²³，确保数据库与最新的结构和结合信息保持同步。PDBbind 被广泛用于验证对接和评分方法²²，其在 CASF 基准测试中的作用进一步巩固了其重要性。PDBbind 因其结构和结合数据的独特结合，特别是精炼集中的数据，已成为基于结构的药物设计中计算方法开发和验证的黄金标准。其在比较评分函数(CASF)基准测试²²中的作用突显了其在该领域的核心重要性。通过 PDBbind+ 平台²²越来越容易访问表明其正在被更广泛地利用。
- 药物设计应用：PDBbind 主要用于验证和开发对接和评分函数²²，这是其主要应用和优势。它也适用于基于结构的虚拟筛选，链接的结构数据可用于对接研究。此外，研究人员可以分析结合亲和力的结构基础，从而理解蛋白质-配体相互作用。
- 数据质量控制：PDBbind 的结合数据经过同行评审的出版物仔细管理²²，这种人工管理确保了准确性。精炼集经过额外的质量控制以确保高精度²²，精炼集的选择标准非常严格。还采用了新的结构处理工作流程以提高整体质量²²，这表明了持续改进数据准确性的努力。
- 现有缺陷和改进方向：最新版本(自 2021 年起)只能通过需要订阅的 PDBbind+ 平台

访问²²，最后一个免费访问版本是 2020 版²²，这种付费模式限制了一些研究人员的访问。核心集不会每年更新²⁶。

3.7. DUDE (Directory of Useful Decoys, Enhanced)

- 当前状态与数据量：DUDE 旨在通过提供具有挑战性的诱饵来帮助基准测试分子对接程序²⁷，其特定目的是评估对接软件区分真实配体和具有相似理化性质的非结合分子的能力。DUDE-E 是原始 DUDE 的增强和重建版本²⁷，此更新旨在解决原始数据集的一些局限性。它包含 22,886 个活性化合物及其对 102 个靶点的亲和力，平均每个靶点 224 个配体²⁷，包含亲和力数据可以更细致地评估对接性能。每个活性化合物提供 50 个诱饵化合物，这些诱饵化合物具有相似的理化性质但不同的 2D 拓扑结构²⁷，这种精心设计的诱饵使得基准测试任务具有挑战性。DUDE 的主要目的是作为评估对接程序区分真实结合物和诱饵能力的基准数据集。精心设计的具有相似性质的诱饵对这些程序提出了重大挑战，模拟了真实世界虚拟筛选场景的难度，其中活性化合物和非活性化合物通常共享相似的特征。102 个靶点数据的可用性²⁸提供了跨不同蛋白质家族的广泛评估。
- 包含信息与属性：DUDE 包含针对 102 个靶点的具有已知亲和力的活性化合物²⁷，亲和力为与对接评分比较提供了基础。每个活性化合物都有诱饵化合物²⁷，这些是基准测试中的阴性对照。DUDE 还包含靶点信息，包括 PDB IDs²⁸，这允许进行基于结构的对接研究。DUDE 包含活性化合物的已知亲和力，这允许定量评估对接程序，使研究人员不仅可以评估程序是否可以识别结合物，还可以评估其预测的结合强度与实验数据相关性的程度。诱饵能够评估其避免假阳性的能力，这是虚拟筛选的关键方面。提供 PDB ID 有助于基于结构的对接和结合模式分析。
- 主要特色与优势：DUDE 专门为基准测试分子对接程序而设计²⁷，这种专注的设计使其与其预期目的高度相关。它提供了一组具有挑战性的诱饵，这些诱饵与活性化合物具有相似的性质²⁷，这种严格的测试有助于识别具有真正预测能力的程序。DUDE 包含 102 个不同靶点的数据²⁸，这允许跨不同蛋白质家族和结合位点特征进行广泛评估。活性化合物具有已知的实验数据，通常来自 ChEMBL²⁹，这为比较提供了可靠的基础。DUDE 专注于基准测试对接，使其成为这些程序的开发人员和用户的专门且有价值的资源。使用真实数据作为活性化合物增加了其相关性，并确保基准测试基于实验结果。wiki 和 Facebook 页面的可用性²⁷促进了社区反馈和问题的识别。
- 药物设计应用：DUDE 主要用于基准测试和比较不同分子对接程序的性能²⁷，这有助于研究人员选择最适合其需求的软件。它还可用于开发和优化对接的评分函数，在 DUDE 上的性能是评估新评分函数的关键指标。
- 数据质量控制：DUDE 对活性化合物进行聚类以确保多样性²⁸，这防止了活性数据集中的冗余。诱饵的生成与活性化合物的理化性质相匹配，同时保持拓扑结构的差异性²⁷，这确保了挑战在于识别真正的结合物，而不是简单地基于基本性质进行区分。从用于生成 LIT-PCBA 的 PubChem 生物测定中移除了假阳性和测定伪影，LIT-PCBA 在基准测试方面与 DUDE 具有一些相似之处²⁹，这突显了解决基准测试数据集偏差的重要性。

- 现有缺陷和改进方向：虽然诱饵集被设计成具有挑战性，但仍然可能存在一些偏差²⁹，这可能导致对对接程序性能的过高估计。DUDE 的重点仅在于对接，限制了其在其他药物设计任务中的使用，它不直接支持 QSAR 或其他基于配体的建模方法。原始的 DUD 和 DUD-E 已被证明存在一些偏差²⁹，研究人员已经识别出可能影响结果的化学偏差。

3.8. LIT-PCBA (Ligand-Target PubChem BioAssays)

- 当前状态与数据量：LIT-PCBA 是一个用于机器学习和虚拟筛选的无偏数据集²⁹，其主要目标是为评估虚拟筛选方法提供更严格、更少偏差的基准。它依赖于 149 个剂量反应 PubChem 生物测定，这些测定经过处理以去除假阳性和测定伪影²⁹，对 PubChem 数据的这种仔细过滤旨在创建一个更高质量的基准。LIT-PCBA 包含 15 个靶点，7844 个已确认的活性化合物和 407,381 个已确认的非活性化合物²⁹，具体的数字清楚地表明了数据集的大小。活性化合物和非活性化合物保持在相似的分子性质范围内²⁹，这确保了虚拟筛选方法不能轻易地基于简单的性质差异来区分它们。LIT-PCBA 通过专注于从 PubChem 生物测定中获得的无偏数据，解决了早期基准数据集（如 DUDE）的局限性。这为评估虚拟筛选方法（特别是依赖于机器学习的方法）提供了更真实的评估，因为它最大限度地减少了可能扭曲其他数据集结果的化学偏差的影响。该数据集模仿了实验筛选平台²⁹，使得基准测试与现实世界的药物发现场景更加相关。
- 包含信息与属性：LIT-PCBA 包含来自 PubChem 的具有已确认生物活性数据的活性和非活性化合物²⁹，剂量反应数据的使用增加了另一层严谨性。它包含 15 个蛋白质靶点的数据，这些靶点至少有一个 X 射线晶体结构可用²⁹，这允许对基于配体和基于结构的虚拟筛选方法进行基准测试。它在命中率和效力分布方面模仿了实验筛选平台²⁹，这使得基准测试更能代表现实世界的药物发现活动。LIT-PCBA 中靶点结构信息的可用性使其适用于对基于配体和基于结构的虚拟筛选方法进行基准测试，为评估不同的计算方法提供了一个通用的平台。现实的命中率²⁹对于评估这些方法的实际适用性及其识别可管理数量的潜在命中化合物以进行进一步实验验证的能力非常重要。
- 主要特色与优势：LIT-PCBA 是一个无偏的数据集，解决了其他基准测试资源的局限性²⁹，这是其主要的突出特点。它来源于高可信度的 PubChem 生物测定数据²⁹，这确保了数据基于实验发现。LIT-PCBA 适用于基准测试基于配体和基于结构的虚拟筛选²⁹，这种多功能性使其对更广泛的方法有价值。它模仿了实验筛选条件²⁹，这增加了基准测试与实际应用的关联性。LIT-PCBA 可在线下载²⁹，这促进了更广泛研究社区的使用。LIT-PCBA 通过提供更真实、更少偏差的数据集，特别是对于评估药物发现中的机器学习方法，代表了虚拟筛选方法基准测试的重大进步。其严格的构建和对模仿实验条件的关注使其成为比早期可能存在偏差的数据集更可靠的方法在现实世界场景中真实性能的指标。
- 药物设计应用：LIT-PCBA 主要用于基准测试新的虚拟筛选方法，特别是那些依赖于机器学习的方法²⁹，其无偏性使其成为评估这些方法的理想选择。它也可用于评估基于配体和基于结构的方法的性能，其设计允许评估这两种类型的方法。
- 数据质量控制：LIT-PCBA 对 PubChem 生物测定进行了严格的处理，以去除假阳性和

伪影²⁹，这确保了数据的可靠性。它还应用了 AVE(非对称验证嵌入)程序来最小化偏差²⁹，这是其构建中解决其他数据集局限性的关键步骤。

- 现有缺陷和改进方向：该数据集仅限于 15 个靶点，这可能无法涵盖药物靶点的全部多样性，更多的靶点将提供更全面的评估。

4. 新整合数据库的Benchmark设计

本节将概述潜在的基准测试策略和具体任务，以评估新的整合小分子数据库的优势。

4.1. 覆盖率提升

- **Benchmark任务 1:**全面的化合物覆盖率：证明新数据库包含比任何单个现有数据库更大且更多样化的小分子集合。这可以通过比较独特化合物的总数以及分析不同化学类别和结构骨架的表示来评估。新的整合数据库的关键优势在于其能够聚合和协调来自多个来源的数据，从而更广泛地覆盖与药物设计相关的化学空间。这种覆盖率的增加可能导致发现可能被单一数据库遗漏的新候选药物。
- **Benchmark任务 2:**增强的靶点和生物活性数据：表明新数据库整合了更全面的靶点信息和生物活性数据，可能通过结合来自 ChEMBL、BindingDB 和 DrugBank 等资源的数据来实现。评估覆盖的独特靶点数量以及生物活性数据的密度(每个靶点具有活性数据的化合物数量)。将来自 DrugBank(富含靶点信息)和 BindingDB(专注于结合亲和力)等专门数据库的靶点和生物活性数据整合到更广泛的数据库中，可以提供更完整的药物-靶点相互作用图，超越简单的二元关系，包括定量测量和详细的靶点注释。
- **Benchmark任务 3:**特定分子/靶点类型的改进覆盖率：关注现有数据库可能存在局限性的特定领域，例如天然产物¹、PROTACs³³或 RNA 靶向小分子³⁴。证明新数据库在这些利基但重要的领域提供卓越的覆盖率，可能通过整合专注于这些分子/靶点类型的专门数据库或数据集来实现。通过专门关注现有数据库中代表性不足的分子或靶点类型来解决这些局限性将是一个显著的改进，能够满足新兴药物发现研究领域的需求，并可能带来新的治疗模式。

4.2. 数据质量提升

- **Benchmark任务 4:**增强的预测准确性：选择一组充分表征的蛋白质靶点和一组具有已知活性的多样化配体(例如，来自 BindingDB 或 PDBbind 精炼集)。使用来自不同单个数据库和新的整合数据库的数据训练计算模型(例如，QSAR 或机器学习模型)，以预测这些配体的活性。证明由于改进的数据质量和一致性，可能通过在整合过程中应用标准化的数据管理和验证流程，在整合数据库上训练的模型实现了更高的预测准确性。整合的关键目标应该是提高数据的整体质量和一致性，从而在药物设计中产生更好的预测模型。这可以通过解决生物活性单位的不一致性、标准化化学标识符以及在整合过程中标记潜在的错误数据点来实现。
- **Benchmark任务 5:**假阳性/阴性的识别：利用特定靶点的已知活性和非活性化合物

(例如, 来自旨在最小化偏差的 LIT-PCBA)。评估不同数据库通过相似性搜索或其他基于配体的方法正确识别这些化合物的能力。表明整合数据库, 由于其潜在改进的数据质量和更少的偏差, 能够更好地分离活性化合物和非活性化合物, 从而在虚拟筛选实验中产生更高的富集因子和更低的假阳性/阴性率。解决假阳性和假阴性问题是虚拟筛选中已知的局限性³⁵, 这将是一个显著的进步。通过整合来自多个来源的数据并应用严格的质量控制措施, 新的数据库有可能减少错误识别的命中或遗漏的活性化合物的数量。

4.3. 信息整合能力

- **Benchmark任务 6: 多属性预测:** 选择一组化合物, 并要求数据库预测多种药理学性质, 例如与主要和脱靶靶点的结合亲和力、ADMET 性质和潜在毒性。新数据库应设计为促进来自不同来源的信息整合, 以提供每个分子的更全面的预测概况, 可能通过链接化学结构、生物活性、靶点信息和理化性质的数据。证明与可能仅涵盖这些性质子的单个数据库相比, 整合数据库可以提供更全面和准确的多属性预测。能够整合不同信息类型以预测一系列药理学性质对于先导化合物优化和降低候选药物风险至关重要。新的整合数据库可以为这种多方面的信息提供单一访问点, 从而简化药物开发过程。
- **Benchmark任务 7: 多药理学和脱靶效应的预测:** 利用已知多药理学药物及其靶点谱(例如, 来自 ChEMBL 或 DrugBank)的数据。评估新数据库通过整合跨不同靶点的生物活性数据(可能使用基于网络的或在整合数据上训练的机器学习模型)来预测这些多靶点相互作用的能力。表明整合数据库可以通过利用来自多个数据库的关于化合物跨广泛靶点活性的组合知识, 更准确地识别潜在的脱靶效应, 这对于安全性评估非常重要。预测多药理学和潜在脱靶效应对于理解药物的安全性和有效性至关重要。整合数据库应通过连接化合物跨广泛靶点的活性来在这方面表现出色, 提供更全面的分子药理学概况和潜在不良反应。

4.4. 用户友好性

- **Benchmark任务 8: 查询效率和数据检索:** 设计一系列复杂的查询, 需要跨多种数据类型进行搜索和过滤(例如, 查找 ZINC 中所有商业可用的化合物, 这些化合物也在 ChEMBL 中列为对特定靶点具有活性且 $K_i < 10$ nM, 并且在 DrugBank 中报告了 ADMET 性质)。测量从单个数据库(使用其各自的界面或 API)和新的整合数据库执行这些查询并检索相关数据所需的时间和精力。证明整合数据库通过统一的界面和潜在优化的数据结构, 提供显著改进的查询效率和更精简的数据检索过程。用户友好性, 包括高效的数据访问和检索, 对于药物设计数据库的实际效用至关重要。新的整合数据库应提供一个单一、直观的界面, 用于访问和组合来自多个来源的数据, 从而节省研究人员的时间和精力。
- **Benchmark任务 9: 数据格式标准化:** 评估整合数据库中数据格式(例如, 生物活性数据的单位、靶点和疾病信息的本体)的一致性和标准化程度, 与单个数据库中观察到的变化进行比较。证明新数据库通过在整合过程中应用一致的数据模型、本体和单位转

换, 提供了更统一和可互操作的数据环境。缺乏数据标准化是阻碍来自不同来源的数据无缝整合和分析的已知问题³⁵。整合数据库应通过建立和执行一致的数据格式和术语来解决这个问题。

4.5. 最新性

- **Benchmark任务 10:** 数据更新的及时性: 跟踪新研究成果(例如, 在关键药物化学期刊中或单个数据库的新版本中)的发表与其纳入新的整合数据库之间的时间延迟。将其与单个数据库的更新频率进行比较。证明新数据库具有更及时地纳入最新数据的机制, 可能通过自动数据摄取管道和对相关来源的持续监控。药物发现领域发展迅速, 因此能够快速整合最新发现的数据库非常有价值。新的整合数据库应努力提供近乎实时的更新, 以确保研究人员能够获得最新的信息。

5. 结论

本报告深入分析了现有的小分子药物设计数据库, 总结了它们各自的优势和局限性。创建新的整合数据库的根本原因是解决这些不足之处。所提出的基准测试策略和任务旨在全面评估新整合资源在药物设计的各个关键方面(包括覆盖率、数据质量、信息整合能力、用户友好性和最新性)的性能和优越性。展望未来, 这样一个整合的数据库有望极大地推动小分子药物发现领域的发展。

表 1: 主要小分子数据库概要(第 3 节)

数据库名称	最新版本(根据研究片段)	大致数据量(分子数量)	主要信息/属性
ChEMBL	34	~240 万化合物	生物活性数据, 靶点, 专利
ZINC	ZINC-22	~370 亿分子	商业可用性, 3D 结构
PubChem	2025 年 1 月	~1.19 亿化合物	综合化学和生物数据
DrugBank	5.1.13	~1.7 万药物	药物-靶点相互作用, 通路
BindingDB	2025 年 3 月	~130 万化合物	结合亲和力
PDBbind	2024	~3.3 万复合物	结构-结合数据
DUDE	DUDE-E	~2.3 万活性化合物	对接诱饵

LIT-PCBA	-	~41.5 万化合物	无偏基准
----------	---	------------	------

引用的著作

1. ChEMBL Database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods | Nucleic Acids Research | Oxford Academic, 访问时间为 四月 5, 2025, <https://academic.oup.com/nar/article/52/D1/D1180/7337608>
2. The ChEMBL Database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods - PubMed, 访问时间为 四月 5, 2025, <https://pubmed.ncbi.nlm.nih.gov/37933841/>
3. ChEMBL 34 is out!, 访问时间为 四月 5, 2025, <http://chembl.blogspot.com/2024/04/chembl-34-is-out.html>
4. Downloads - ChEMBL Interface Documentation - GitBook, 访问时间为 四月 5, 2025, <https://chembl.gitbook.io/chembl-interface-documentation/downloads>
5. BindingDB in 2024: a FAIR knowledgebase of protein-small molecule binding data | Nucleic Acids Research | Oxford Academic, 访问时间为 四月 5, 2025, <https://academic.oup.com/nar/article/53/D1/D1633/7906836>
6. ZINC Dataset | Papers With Code, 访问时间为 四月 5, 2025, <https://paperswithcode.com/dataset/zinc>
7. ZINC database - Wikipedia, 访问时间为 四月 5, 2025, https://en.wikipedia.org/wiki/ZINC_database
8. ZINC-22—A Free Multi-Billion-Scale Database of Tangible Compounds for Ligand Discovery - PMC, 访问时间为 四月 5, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC9976280/>
9. ZINC | re3data.org, 访问时间为 四月 5, 2025, <https://www.re3data.org/repository/r3d100010372>
10. ZINC20—A Free Ultralarge-Scale Chemical Database for Ligand Discovery, 访问时间为 四月 5, 2025, <https://pubs.acs.org/doi/10.1021/acs.jcim.0c00675>
11. PubChem 2025 update | Nucleic Acids Research - Oxford Academic, 访问时间为 四月 5, 2025, <https://academic.oup.com/nar/article/53/D1/D1516/7903365>
12. PubChem 2023 update - PMC - National Institutes of Health (NIH), 访问时间为 四月 5, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC9825602/>
13. Data Sources - PubChem, 访问时间为 四月 5, 2025, <https://pubchem.ncbi.nlm.nih.gov/sources/>
14. PubChem in 2021: new data content and improved web interfaces | Nucleic Acids Research, 访问时间为 四月 5, 2025, <https://academic.oup.com/nar/article/49/D1/D1388/5957164>
15. (PDF) PubChem in 2021: New data content and improved web interfaces - ResearchGate, 访问时间为 四月 5, 2025, https://www.researchgate.net/publication/346175796_PubChem_in_2021_New_data_content_and_improved_web_interfaces
16. DrugBank | re3data.org, 访问时间为 四月 5, 2025, <https://www.re3data.org/repository/r3d100010544>

17. About DrugBank | DrugBank Online, 访问时间为 四月 5, 2025, <https://go.drugbank.com/about>
18. DrugBank 6.0: the DrugBank Knowledgebase for 2024 - PubMed, 访问时间为 四月 5, 2025, <https://pubmed.ncbi.nlm.nih.gov/37953279/>
19. Binding Database Home, 访问时间为 四月 5, 2025, <https://www.bindingdb.org/>
20. BindingDB in 2024: a FAIR Knowledgebase of Protein-Small Molecule Binding Data | Biological and Medicinal Chemistry | ChemRxiv | Cambridge Open Engage, 访问时间为 四月 5, 2025, <https://chemrxiv.org/engage/chemrxiv/article-details/66e360db12ff75c3a12b3a00>
21. BindingDB Dataset | Papers With Code, 访问时间为 四月 5, 2025, <https://paperswithcode.com/dataset/bindingdb>
22. PDBbind+, 访问时间为 四月 5, 2025, <https://www.pdbbind-plus.org.cn/>
23. Welcome to PDBbind-CN database, 访问时间为 四月 5, 2025, <http://www.pdbbind.org.cn/>
24. PDB-wide collection of binding data: current status of the PDBbind database - PubMed, 访问时间为 四月 5, 2025, <https://pubmed.ncbi.nlm.nih.gov/25301850/>
25. PDB-wide collection of binding data: current status of the PDBbind database | Bioinformatics | Oxford Academic, 访问时间为 四月 5, 2025, <https://academic.oup.com/bioinformatics/article/31/3/405/2365195>
26. Prof. Renxiao Wang's group - Welcome to PDBbind-CN database, 访问时间为 四月 5, 2025, <http://www.pdbbind.org.cn/index.php?newsid=22>
27. DUD-E: A Database of Useful (Docking) Decoys — Enhanced, 访问时间为 四月 5, 2025, <https://dude.docking.org/>
28. All Targets | DUD-E: A Database of Useful (Docking) Decoys — Enhanced, 访问时间为 四月 5, 2025, <https://dude.docking.org/targets>
29. LIT-PCBA: An unbiased dataset for machine learning and virtual screening - ResearchGate, 访问时间为 四月 5, 2025, https://www.researchgate.net/publication/340614114_LIT-PCBA_An_unbiased_dataset_for_machine_learning_and_virtual_screening
30. LIT-PCBA: An Unbiased Data Set for Machine Learning and Virtual Screening - PubMed, 访问时间为 四月 5, 2025, <https://pubmed.ncbi.nlm.nih.gov/32282202/>
31. LIT-PCBA: An Unbiased Data Set for Machine Learning and Virtual Screening | Journal of Chemical Information and Modeling - ACS Publications, 访问时间为 四月 5, 2025, <https://pubs.acs.org/doi/10.1021/acs.jcim.0c00155>
32. LIT-PCBA(KAT2A) Benchmark (Drug Discovery) | Papers With Code, 访问时间为 四月 5, 2025, <https://paperswithcode.com/sota/drug-discovery-on-lit-pcba-kat2a>
33. New Technologies and Methods in Small Molecule Drug Development - BOC Sciences, 访问时间为 四月 5, 2025, <https://www.bocsci.com/blog/new-technologies-and-methods-in-small-molecule-drug-development/>
34. Exploring chemical space for “druglike” small molecules in the age of AI - Frontiers, 访问时间为 四月 5, 2025, <https://www.frontiersin.org/journals/molecular-biosciences/articles/10.3389/fmolb.2025.1553667/epub>
35. 7 Limitations of Molecular Docking & Computer Aided Drug Design and

Discovery, 访问时间为 四月 5, 2025,

<https://amitray.com/7-limitations-of-molecular-docking-computer-aided-drug-design-and-discovery/>

36. (PDF) Three pillars for ensuring public access and integrity of chemical databases powering cheminformatics - ResearchGate, 访问时间为 四月 5, 2025,
https://www.researchgate.net/publication/390309735_Three_pillars_for_ensuring_public_access_and_integrity_of_chemical_databases_powering_cheminformatics
37. Data Curation Issues in the Chemical Sciences | NISO website, 访问时间为 四月 5, 2025,
<https://www.niso.org/niso-io/2013/09/data-curation-issues-chemical-sciences>